

LAPORAN TEKNIS KOMPREHENSIF
“Data Scientist”

ID Tim Capstone Project	CC26-PSU272
Judul Proyek	EcoSort AI “Sistem Cerdas Klasifikasi Sampah dan Rekomendasi Daur Ulang Berbasis <i>Computer Vision</i> ”.
Tema yang Dipilih	Sustainable Living & Responsible Consumption
List Anggota	1. CDCC284D6Y0355) - (Muhammad Aqsa Firdaus) - (Data Scientist) - [Aktif] 2. (CDCC284D6Y2387) - (Muhamad Alfa Reza Gobel) - (Data Scientist) - [Aktif] 3. (CFCC284D6Y0292) - (Muhammad Dafa Alvin Zuhdi) - (Full-Stack Web Developer) - [Aktif] 4. (CFCC284D6X2854) - (Cathrine Natalia Koeswandono) - (Full-Stack Web Developer) - [Aktif] 5. (CACCC284D6X1912) - (Maysahayu Artika Maharani) - (AI Engineer) - [Aktif] 6. (CACCC284D6X0877) - (Putri Manika Rukmamaya) - (AI Engineer) - [Aktif]

DAFTAR ISI

DAFTAR ISI.....	i
DAFTAR TABEL.....	ii
DAFTAR GAMBAR	iii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang.....	1
1.2 Identifikasi Masalah.....	1
1.3 Tujuan Proyek.....	2
1.4 Solusi yang Dikembangkan	2
BAB II DATA UNDERSTANDING & DATA WRANGLING	3
2.1 Sumber Data.....	3
2.2 Gathering Data	4
2.3 Asessing Data.....	5
2.4 Cleaning Data.....	6
BAB III ANALISIS DATA DAN VISUALISASI.....	9
3.1 Exploratory Data Analysis.....	9
3.2 Explanatory Data Analysis	11
3.3 Kesimpulan Analisis	15
BAB IV FEATURE ENGINEERING & A/B TESTING.....	16
4.1 Feature Engineering	16
4.2 A/B Testing.....	17
BAB V DASHBOARD & DEPLOYMENT	19
5.1. Dashboard Streamlit.....	19
5.2. Deployment Streamlit Cloud	20
BAB VI KESIMPULAN & SARAN.....	21
6.1 Kesimpulan	21
6.2 Saran	21
LAMPIRAN.....	23

DAFTAR TABEL

Tabel 2.1 Sumber Dataset	3
Tabel 2.2 Kategori Sampah.....	4
Tabel 2.3 Pemeriksaan Data Duplikat	6
Tabel 2.4 Peningkatan Kualitas Citra	8
Tabel 4.1 Uji Asumsi A/B Testing Data Klasifikasi Sampah.....	17
Tabel 4.2 Hasil Pengujian A/B Testing Data Klasifikasi Sampah.....	17
Tabel 4.3 Hasil Pengujian A/B Testing Data Bank Sampah	18

DAFTAR GAMBAR

Gambar 2.1 Contoh Gambar Duplikat	5
Gambar 2.2 Contoh Proses Cleaning Gambar	8
Gambar 3.1 Distribusi Jumlah Data per Kelas.....	9
Gambar 3.2 Distribusi Ukuran Gambar	10
Gambar 3.3 Distribusi Brightness Gambar.....	10
Gambar 3.4 Sampel Gambar.....	11
Gambar 3.5 Resize Gambar	11
Gambar 3.6 Visualisasi Ukuran Gambar	12
Gambar 3.7 Perbandingan Format File.....	12
Gambar 3.8 Perbandingan Jumlah Data Duplikat.....	13
Gambar 3.9 Distribusi Brightness Setelah Cleaning.....	13
Gambar 3.10 Distribusi Rata-rata Warna.....	14
Gambar 3.11 Visualisasi Persebaran Fitur Menggunakan PCA	14
Gambar 4.1 Contoh Hasil Feature Engineering.....	16
Gambar 5.1 Halaman Dataset Streamlit.....	20
Gambar 5.2 Halaman Dashboard Analysis Streamlit	20

BAB I

PENDAHULUAN

1.1 Latar Belakang

Permasalahan sampah masih menjadi salah satu isu lingkungan yang terus dihadapi Indonesia. Rendahnya kesadaran masyarakat dalam memilah sampah serta belum optimalnya proses klasifikasi sampah menyebabkan banyak sampah tercampur dan berakhir di Tempat Pembuangan Akhir (TPA) tanpa melalui proses pemilahan yang tepat. Kondisi tersebut mengakibatkan berkurangnya efektivitas daur ulang, meningkatnya volume sampah yang menumpuk, serta menimbulkan berbagai dampak negatif terhadap lingkungan.

Berdasarkan data Sistem Informasi Pengelolaan Sampah Nasional (SIPSN) yang dikutip dalam penelitian "Implementasi Computer Vision untuk Klasifikasi Sampah Berbasis Deep Learning", total timbulan sampah di Indonesia pada tahun 2022 mencapai sekitar 20,02 juta ton. Selain itu, jumlah sampah nasional juga mengalami peningkatan dari 65 juta ton pada tahun 2016 menjadi 66,5 juta ton pada tahun 2018. Data tersebut menunjukkan bahwa permasalahan sampah masih menjadi tantangan yang memerlukan solusi inovatif dan berkelanjutan.

Perkembangan teknologi Artificial Intelligence (AI), khususnya Computer Vision, membuka peluang untuk membantu proses pengelolaan sampah secara lebih efektif. Teknologi ini memungkinkan sistem mengenali karakteristik visual suatu objek dan mengelompokkannya secara otomatis berdasarkan kategori tertentu. Dalam konteks pengelolaan sampah, teknologi Computer Vision dapat dimanfaatkan untuk mengidentifikasi jenis sampah sehingga proses pemilahan dapat dilakukan dengan lebih cepat dan akurat.

Berdasarkan kondisi tersebut, dikembangkan proyek EcoSort AI, yaitu sistem cerdas klasifikasi sampah berbasis Computer Vision yang mampu mengidentifikasi jenis sampah secara otomatis dan memberikan rekomendasi pengelolaan atau daur ulang yang sesuai. Sistem ini diharapkan dapat membantu masyarakat dalam memilah sampah dengan lebih mudah, meningkatkan kesadaran terhadap pengelolaan sampah yang bertanggung jawab, serta mendukung penerapan konsep sustainable living dan responsible consumption.

1.2 Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan, diperoleh beberapa permasalahan utama sebagai berikut:

- 1) Rendahnya kesadaran masyarakat dalam melakukan pemilahan sampah berdasarkan jenisnya.

- 2) Proses identifikasi dan klasifikasi sampah masih banyak dilakukan secara manual sehingga kurang efisien dan rentan terhadap kesalahan.
- 3) Masyarakat sering mengalami kesulitan dalam menentukan metode pengelolaan atau daur ulang yang sesuai untuk setiap jenis sampah
- 4) Belum tersedia sistem yang mampu membantu proses klasifikasi sampah secara otomatis sekaligus memberikan informasi pengelolaan sampah yang tepat.
- 5) Data dan informasi mengenai lokasi bank sampah masih belum mudah diakses oleh masyarakat secara praktis

1.3 Tujuan Proyek

Proyek EcoSort AI dikembangkan dengan tujuan sebagai berikut:

- 1) Menyiapkan dan menghasilkan dataset gambar sampah yang berkualitas melalui proses data wrangling, exploratory data analysis, feature engineering, dan validasi kualitas data.
- 2) Mengidentifikasi karakteristik visual setiap kategori sampah melalui analisis data dan visualisasi sehingga dapat mendukung proses pengembangan model klasifikasi.
- 3) Membangun dashboard interaktif berbasis Streamlit untuk menyajikan insight, hasil analisis, serta informasi terkait dataset yang digunakan dalam proyek.
- 4) Mendukung pengembangan sistem klasifikasi sampah otomatis berbasis Computer Vision yang mampu mengelompokkan sampah ke dalam kategori B3, Glass, Metal, Organic, Paper, dan Plastic.
- 5) Mendukung penyediaan rekomendasi pengelolaan sampah dan informasi bank sampah sebagai bagian dari solusi pengelolaan sampah yang berkelanjutan.

1.4 Solusi yang Dikembangkan

Solusi yang dikembangkan dalam proyek ini adalah EcoSort AI (Eco Sorting Artificial Intelligence), yaitu sistem klasifikasi sampah berbasis Computer Vision yang memanfaatkan teknologi Deep Learning untuk mengidentifikasi jenis sampah secara otomatis berdasarkan gambar yang diunggah pengguna. Pada proyek ini, tim Data Science berfokus pada proses persiapan dan analisis data yang mencakup pengumpulan dataset, asesmen kualitas data, pembersihan data, exploratory data analysis (EDA), feature engineering, serta pembuatan dashboard analisis menggunakan Streamlit. Seluruh proses tersebut dilakukan untuk memastikan data yang digunakan memiliki kualitas yang baik dan siap digunakan pada tahap pengembangan model AI.

Melalui solusi yang dikembangkan, EcoSort AI diharapkan mampu membantu pengguna dalam mengenali jenis sampah secara lebih cepat, memperoleh informasi pengelolaan sampah yang sesuai, serta meningkatkan kesadaran masyarakat terhadap pentingnya pemilahan dan daur ulang sampah guna mendukung lingkungan yang lebih berkelanjutan.

BAB II

DATA UNDERSTANDING & DATA WRANGLING

2.1 Sumber Data

Tabel 2.1 Sumber Dataset

No	Nama Dataset	Deskripsi	Tujuan	Tautan
1	Waste Classification Dataset	Dataset citra sampah organik dan anorganik yang digunakan untuk tugas klasifikasi sampah berbasis Computer Vision.	Melatih model klasifikasi sampah organik dan anorganik.	<u>Kaggle</u>
2	Waste Classification Data	Dataset citra sampah rumah tangga yang terdiri atas kategori organik dan recyclable.	Menambah variasi data pelatihan dan meningkatkan performa model klasifikasi.	<u>Kaggle</u>
3	Data Lokasi Bank Sampah Kota Surabaya	Dataset informasi lokasi bank sampah di Kota Surabaya.	Membangun sistem rekomendasi bank sampah terdekat berdasarkan lokasi pengguna.	<u>Satu Data Surabaya</u>
4	Data Artikel Edukasi Sampah	Dataset hasil scraping artikel terkait pengelolaan sampah, daur ulang, bahaya limbah, dan gerakan 3R yang telah dikategorikan berdasarkan jenis sampah.	Digunakan sebagai rekomendasi artikel untuk menyediakan informasi edukatif mengenai dampak dan pengelolaan sampah sesuai kategori sampah yang terdeteksi oleh sistem.	<u>Mongabay</u>

2.2 Gathering Data

Tahap gathering data dilakukan untuk mengumpulkan seluruh data yang diperlukan dalam pengembangan proyek EcoSort AI. Data yang dikumpulkan terdiri atas dataset gambar sampah untuk kebutuhan klasifikasi, dataset lokasi pengangkutan sampah yang digunakan sebagai informasi pendukung dan dataset artikel untuk mendukung fitur rekomendasi artikel.

Dataset 1: Waste Classification Dataset

Waste Classification Dataset merupakan kumpulan data citra sampah yang diperoleh dari dua dataset berbeda pada platform Kaggle. Kedua dataset tersebut digabungkan dan dipilah sesuai kategori yang diperlukan sehingga dapat digunakan sebagai data utama dalam pengembangan sistem klasifikasi sampah. Kategori yang digunakan meliputi:

Tabel 2.2 Kategori Sampah

Kategori	Jumlah Gambar
B3	200
Glass	200
Metal	200
Organic	200
Paper	200
Plastic	200
Total	1200

Kategori B3 merupakan hasil penggabungan beberapa jenis limbah elektronik dengan jumlah masing-masing jenis sebanyak 50 gambar, yaitu: Battery, Mobile, PCB, dan Television.

Dataset 2: Data Lokasi Pengangkutan Sampah Surabaya

Dataset diperoleh dari portal Open Data Kota Surabaya dan digunakan untuk menyediakan informasi lokasi pengelolaan sampah. Dataset terdiri atas 229 data lokasi, 37 kecamatan, dan 128 kelurahan.

Dataset 3: Data Artikel Edukasi Sampah

Dataset ini diperoleh melalui proses web scraping dari artikel-artikel yang dipublikasikan oleh Mongabay Indonesia dan beberapa sumber pendukung lainnya. Dataset berisi informasi mengenai pengelolaan sampah, daur ulang, bahaya limbah, gerakan 3R (*Reduce, Reuse, Recycle*), serta berbagai isu lingkungan yang berkaitan dengan persampahan. Data yang diperoleh kemudian disimpan dan diberi label berdasarkan kategori sampah yang relevan. Dataset ini digunakan sebagai sumber informasi untuk mendukung fitur rekomendasi artikel, sehingga pengguna dapat memperoleh informasi mengenai dampak lingkungan dan pengelolaan sampah. Dataset terdiri atas 70 artikel, 6 label kategori, dan dalam format json.

2.3 Asessing Data

Tahap assessing data dilakukan untuk mengevaluasi kualitas dan kondisi dataset yang telah diperoleh pada tahap gathering data. Proses ini bertujuan untuk mengidentifikasi berbagai permasalahan yang berpotensi memengaruhi proses analisis dan pengembangan model, seperti data duplikat, file corrupt, ketidakkonsistenan format file, variasi ukuran gambar, serta karakteristik pencahayaan pada citra. Melalui tahap assessing data, kondisi awal dataset dapat dipahami secara lebih menyeluruh sehingga tindakan pembersihan dan persiapan data yang sesuai dapat dilakukan pada tahap cleaning data.

1) Pemeriksaan Jumlah Data

Pemeriksaan jumlah data dilakukan untuk mengetahui distribusi gambar pada setiap kategori sampah yang digunakan dalam proyek EcoSort AI. Hasil pemeriksaan menunjukkan bahwa dataset terdiri atas 1.200 gambar yang terbagi ke dalam enam kategori, yaitu B3, Glass, Metal, Organic, Paper, dan Plastic yang masing-masing berjumlah 200 gambar. Distribusi data yang seimbang antar kategori diharapkan dapat membantu proses pembelajaran model menjadi lebih optimal.

2) Pemeriksaan File Corrupt

Pemeriksaan file corrupt dilakukan untuk memastikan seluruh gambar dapat dibaca dan diproses dengan baik pada tahap analisis maupun pengembangan model. Hasil pemeriksaan menunjukkan bahwa tidak ditemukan file corrupt pada dataset sehingga seluruh gambar dapat digunakan pada tahap selanjutnya.

3) Pemeriksaan Ukuran Gambar

Pemeriksaan ukuran gambar dilakukan untuk mengetahui konsistensi dimensi citra yang digunakan dalam dataset. Hasil pemeriksaan menunjukkan bahwa sebagian besar gambar memiliki ukuran yang bervariasi seperti (184, 274), (150, 150), (512, 384) dan tidak ditemukan gambar dengan ukuran kurang dari 100 piksel. Hal ini menunjukkan bahwa kualitas gambar yang digunakan sudah cukup baik untuk proses pengolahan lebih lanjut.

4) Pemeriksaan Data Duplikat



Gambar 2.1 Contoh Gambar Duplikat

Pemeriksaan data duplikat dilakukan menggunakan metode hashing MD5, yaitu teknik yang menghasilkan kode identitas unik untuk setiap gambar berdasarkan

isi filenya. Gambar yang memiliki kode hash yang sama dikategorikan sebagai data duplikat. Hasil pemeriksaan menunjukkan terdapat 3 gambar duplikat dalam dataset yang perlu dihapus pada tahap cleaning untuk menghindari bias pada proses pembelajaran model.

Tabel 2.3 Pemeriksaan Data Duplikat

Aspek	Hasil
Total Data	1200
File Corrupt	0
Ukuran Gambar	(184, 274), (150, 150), (512, 384)
Data Duplikat	3
Format File	JPG : 1146 JPEG : 54
Tingkat Kecerahan	Minimum : 25.22 Maksimum : 247.02 Rata - Rata : 157.38

Berdasarkan hasil assessing data, dataset EcoSort AI memiliki kualitas yang cukup baik karena tidak ditemukan file corrupt maupun gambar dengan ukuran yang terlalu kecil. Namun, masih terdapat ketidakkonsistenan format file antara JPG dan JPEG serta ditemukan 3 data duplikat yang perlu ditangani pada tahap cleaning. Selain itu, distribusi brightness menunjukkan variasi pencahayaan yang masih berada dalam rentang wajar sehingga dataset dinilai cukup representatif untuk proses analisis dan pengembangan model. Oleh karena itu, tahap cleaning dilakukan untuk meningkatkan konsistensi dan kualitas dataset sebelum digunakan pada tahap berikutnya.

2.4 Cleaning Data

Tahap cleaning data dilakukan untuk memperbaiki kualitas dan konsistensi dataset berdasarkan temuan yang diperoleh pada tahap assessing data. Proses ini bertujuan untuk menangani berbagai permasalahan yang ditemukan, seperti data duplikat, ketidakkonsistenan format file, serta perbedaan karakteristik data yang berpotensi memengaruhi proses analisis dan pengembangan model. Melalui tahap cleaning data, dataset dipersiapkan agar memiliki kualitas yang lebih baik, lebih konsisten, dan lebih siap digunakan pada tahap Exploratory Data Analysis (EDA).

1) Penghapusan Data Duplikat

Proses penghapusan data duplikat dilakukan berdasarkan hasil identifikasi menggunakan hashing MD5, yaitu teknik yang menghasilkan kode identitas unik untuk setiap gambar berdasarkan isi filenya. Gambar yang memiliki kode hash yang sama dikategorikan sebagai data duplikat. Sebanyak 3 gambar yang

terdeteksi memiliki kode identik berhasil dihapus dari dataset. Langkah ini dilakukan untuk mengurangi risiko overfitting dan memastikan setiap gambar memberikan informasi yang unik bagi model.

2) Standarisasi Format File

Proses standarisasi format file dilakukan dengan mengonversi seluruh gambar ke format JPG. Sebelum cleaning, dataset terdiri dari 1.146 file JPG dan 54 file JPEG. Setelah proses standarisasi dilakukan, seluruh gambar berhasil diseragamkan ke format JPG sehingga meningkatkan konsistensi dataset dan mempermudah proses pemuatan data.

3) Standarisasi Nama File

Proses standarisasi nama file dilakukan untuk menciptakan struktur penamaan yang konsisten dan terorganisir pada seluruh gambar dalam dataset. Sebelum proses renaming, setiap gambar memiliki nama file yang berbeda-beda sesuai sumber dataset, seperti kombinasi angka, karakter acak, atau nama yang tidak mencerminkan kategori gambar. Kondisi tersebut dapat menyulitkan proses pengelolaan dataset, pelacakan data, maupun proses validasi pada tahap analisis dan pengembangan model. Untuk mengatasi permasalahan tersebut, setiap gambar diberi nama baru berdasarkan kategori kelas dan nomor urutnya. Format penamaan yang digunakan adalah:

O_10020.jpg → Organic_109.jpg

glass150.jpg → Glass_029.jpg


paper276.jpg → Paper_096.jpg

4) Standarisasi Ukuran Gambar

Proses standarisasi ukuran gambar dilakukan untuk memastikan seluruh gambar memiliki dimensi yang konsisten sebelum digunakan pada tahap training model. Berdasarkan hasil assessing data, ukuran gambar dalam dataset masih cukup bervariasi karena berasal dari berbagai sumber dan proses pengambilan gambar yang berbeda. Variasi ukuran ini dapat menyebabkan ketidakkonsistenan pada data input dan berpotensi memengaruhi proses pembelajaran model. Oleh karena itu, seluruh gambar diubah menjadi ukuran 300×300 piksel agar memiliki dimensi yang seragam. Konsistensi ukuran gambar penting untuk menghasilkan format input yang standar sehingga proses pembelajaran model dapat berjalan lebih stabil dan efisien.

5) Peningkatan Kualitas Citra

Peningkatan kualitas citra dilakukan melalui proses denoising dan normalisasi, tahap ini bertujuan untuk menghasilkan data gambar yang lebih bersih dan konsisten sebelum digunakan pada proses analisis maupun pengembangan model. Proses denoising dilakukan menggunakan metode Gaussian Blur untuk mengurangi noise atau gangguan visual yang dapat muncul akibat kualitas kamera, kondisi pencahayaan, maupun proses kompresi gambar. Pengurangan noise membantu mempertahankan karakteristik utama objek sampah sehingga informasi visual yang penting dapat lebih mudah dikenali.



Gambar 2.2 Contoh Proses Cleaning Gambar

Selanjutnya dilakukan normalisasi nilai piksel dengan mengubah rentang nilai intensitas dari 0–255 menjadi 0–1. Normalisasi bertujuan untuk menyeragamkan skala data sehingga proses komputasi menjadi lebih stabil dan efisien. Selain itu, normalisasi juga membantu algoritma deep learning dalam mempercepat proses konvergensi dan meningkatkan performa model selama proses pelatihan.

Tabel 2.4 Peningkatan Kualitas Citra

Aspek	Sebelum	Sesudah
Total Data	1200	1197
Data Duplikat	3	0
Format File	JPG : 1146 JPEG : 54	JPG : 1200
Nama File	O_10020.jpg	Organic_109.jpg
Ukuran Gambar	(184, 274), (150, 150), (512, 384)	(300, 300)

Berdasarkan hasil cleaning data yang telah dilakukan, kualitas dan konsistensi dataset berhasil ditingkatkan melalui beberapa tahapan, yaitu penghapusan data duplikat, standardisasi format file, standardisasi nama file, serta penyeragaman ukuran gambar. Selain meningkatkan kualitas data, hasil cleaning tidak langsung diterapkan pada dataset asli. Seluruh data yang telah dibersihkan disimpan pada dataset baru bernama Dataset Cleaned sehingga dataset asli tetap terjaga dan dapat digunakan sebagai data referensi apabila diperlukan pada tahap evaluasi atau validasi proses cleaning. Pendekatan ini dilakukan untuk menghindari perubahan permanen pada data mentah (raw dataset) serta memastikan proses pengolahan data dapat dilakukan secara lebih aman, terstruktur, dan terdokumentasi dengan baik.

BAB III


ANALISIS DATA DAN VISUALISASI

3.1 Exploratory Data Analysis

Pada tahap ini dilakukan Exploratory Data Analysis (EDA) untuk memahami karakteristik dataset gambar sampah yang digunakan dalam proyek EcoSort AI. Analisis dilakukan terhadap distribusi data, ukuran gambar, tingkat kecerahan, serta variasi visual antar kategori sampah. Hasil EDA digunakan untuk memperoleh pemahaman awal mengenai kualitas dan karakteristik dataset sebelum digunakan pada tahap pengembangan model.

1) Distribusi Jumlah Data per Kelas

Analisis distribusi jumlah data per kelas dilakukan untuk mengetahui keseimbangan jumlah gambar pada setiap kategori sampah. Keseimbangan distribusi data penting untuk mengurangi potensi bias model terhadap kategori tertentu selama proses pelatihan.




Gambar 3.1 Distribusi Jumlah Data per Kelas

Berdasarkan hasil visualisasi, kategori B3, Organic dan plastik memiliki jumlah data yaitu 199 gambar karena ada beberapa gambar duplikat yang sudah dihapus, sedangkan kategori Glass, Metal, Paper masing-masing memiliki 200 gambar. Meskipun beberapa kategori memiliki jumlah data lebih sedikit dibanding kategori lainnya, distribusi dataset secara keseluruhan masih tergolong cukup seimbang dan dapat digunakan sebagai dasar pengembangan model klasifikasi sampah.

2) Distribusi Ukuran Gambar

Analisis ukuran gambar dilakukan untuk mengetahui konsistensi dimensi gambar yang digunakan dalam dataset. Konsistensi ukuran gambar sangat penting karena model computer vision umumnya memerlukan ukuran input yang seragam.




Gambar 3.2 Distribusi Ukuran Gambar

Setelah proses cleaning dilakukan, distribusi ukuran gambar menjadi lebih konsisten dengan dominasi ukuran gambar yang seragam yaitu lebar 300 piksel dan tinggi 300 piksel. Hal ini menunjukkan bahwa proses cleaning berhasil meningkatkan kualitas dataset dan mempermudah proses preprocessing pada tahap training model. Konsistensi ukuran gambar membantu model menerima input yang lebih stabil sehingga proses pembelajaran dapat berjalan lebih optimal.

3) Distribusi Kecerahan

Analisis brightness dilakukan untuk mengetahui tingkat pencahayaan gambar yang terdapat dalam dataset. Variasi brightness dapat memengaruhi kemampuan model dalam mengenali objek pada kondisi pencahayaan yang berbeda.




Gambar 3.3 Distribusi Brightness Gambar

Distribusi brightness menunjukkan bahwa dataset memiliki tingkat pencahayaan yang cukup beragam dengan mayoritas gambar berada pada tingkat brightness menengah hingga tinggi. Rata-rata distribusi brightness berkisar pada rentang nilai menengah sehingga menunjukkan bahwa sebagian besar gambar memiliki pencahayaan yang cukup baik. Variasi pencahayaan ini menunjukkan bahwa gambar diambil pada kondisi lingkungan yang berbeda-beda sehingga dataset menjadi lebih representatif terhadap kondisi nyata.

4) Visualisasi Sampel Gambar

Visualisasi sampel gambar dilakukan untuk memahami karakteristik visual dari masing-masing kategori sampah secara langsung. Analisis ini membantu mengidentifikasi perbedaan bentuk, warna, tekstur, dan latar belakang antar kategori.




Gambar 3.4 Sampel Gambar

Berdasarkan sampel gambar yang ditampilkan, setiap kategori sampah memiliki karakteristik visual yang berbeda. Kategori paper didominasi warna alami seperti putih, sedangkan kategori plastik cenderung memiliki warna seperti hijau, biru dan bening. Variasi karakteristik visual ini dapat menjadi informasi penting yang dipelajari oleh model klasifikasi.

5) Perbandingan Sebelum dan Sesudah Resize

Analisis ini dilakukan untuk memastikan bahwa proses resize berhasil menghasilkan ukuran gambar yang seragam tanpa menghilangkan informasi visual penting yang terdapat pada objek sampah.



Gambar 3.5 Resize Gambar


Hasil visualisasi menunjukkan bahwa proses resize berhasil menyeragamkan ukuran gambar yang awalnya ukuran sangat bervariasi menjadi (300, 300) tanpa mengubah karakteristik utama objek. Objek sampah tetap dapat dikenali dengan baik setelah proses resize sehingga data siap digunakan pada tahap preprocessing dan training model.

3.2 Explanatory Data Analysis

Setelah dilakukan eksplorasi terhadap karakteristik dataset, tahap selanjutnya adalah explanatory analysis untuk menjawab pertanyaan bisnis yang telah ditetapkan. Analisis dilakukan menggunakan berbagai visualisasi dan teknik ekstraksi fitur guna memperoleh insight yang dapat mendukung pengembangan sistem EcoSort AI.


1) Pertanyaan Bisnis 1

Apakah kualitas dataset gambar sampah berdasarkan konsistensi ukuran gambar, format file, dan jumlah data duplikat sudah memenuhi kebutuhan proses training model pada tahap persiapan data?




Gambar 3.6 Visualisasi Ukuran Gambar

Visualisasi menunjukkan bahwa dataset sebelum proses cleaning memiliki variasi ukuran gambar yang cukup beragam. Sebagian besar gambar memiliki ukuran besar sekitar 500 piksel, namun masih terdapat beberapa gambar dengan ukuran yang lebih kecil dan tidak konsisten. Setelah proses cleaning dilakukan, distribusi ukuran gambar menjadi lebih konsisten dengan dominasi ukuran gambar yang seragam. Hal ini menunjukkan bahwa proses cleaning berhasil meningkatkan kualitas dataset dan mempermudah proses preprocessing pada tahap training model. Konsistensi ukuran gambar membantu model menerima input yang lebih stabil sehingga proses pembelajaran dapat berjalan lebih optimal.



Gambar 3.7 Perbandingan Format File

Sebelum proses cleaning, dataset masih terdiri dari beberapa format file yaitu JPG dan JPEG. Format JPG mendominasi dataset dengan persentase sekitar 95.5%, sedangkan format JPEG hanya sebagian kecil dari keseluruhan dataset dengan persentase 4.5%. Setelah cleaning dilakukan, seluruh gambar berhasil diseragamkan ke dalam format JPG sehingga dataset menjadi lebih konsisten. Standardisasi format file membantu mengurangi potensi error pada proses loading data dan membuat pipeline preprocessing menjadi lebih stabil dan efisien.




Gambar 3.8 Perbandingan Jumlah Data Duplikat

Sebelum proses cleaning, dataset masih memiliki 3 data duplikat. Setelah cleaning dilakukan, seluruh data duplikat berhasil dihapus sehingga jumlah data duplikat menjadi 0. Penghapusan data duplikat sangat penting untuk mengurangi risiko overfitting pada model deep learning. Data yang berulang dapat menyebabkan model terlalu menghafal pola tertentu dan menurunkan kemampuan generalisasi terhadap data baru.


2) Pertanyaan Bisnis 2

Bagaimana distribusi warna dan tingkat pencahayaan pada setiap kategori sampah memengaruhi kebutuhan preprocessing gambar dalam pengembangan model EcoSort AI?



Gambar 3.9 Distribusi Brightness Setelah Cleaning

Distribusi brightness menunjukkan bahwa dataset memiliki tingkat pencahayaan yang cukup beragam dengan mayoritas gambar berada pada tingkat brightness menengah hingga tinggi. Rata-rata distribusi brightness berkisar di angka 150 hingga 200, Variasi pencahayaan ini menunjukkan bahwa gambar diambil pada kondisi lingkungan yang berbeda-beda sehingga dataset menjadi lebih representatif terhadap kondisi nyata. Namun, variasi brightness yang terlalu ekstrem tetap perlu ditangani melalui preprocessing seperti normalisasi dan augmentasi brightness agar model lebih robust terhadap perubahan pencahayaan.




Gambar 3.10 Distribusi Rata-rata Warna

Visualisasi distribusi rata-rata warna menunjukkan bahwa kanal warna Red, Green, dan Blue memiliki sebaran intensitas yang cukup beragam. Kanal warna merah berada pada nilai sekitar 170, lebih tinggi dibandingkan hijau (± 163) dan Blue (± 154). Hal ini menunjukkan bahwa dataset memiliki variasi karakteristik visual antar kategori sampah, seperti warna alami pada sampah organik serta warna reflektif pada kategori kaca dan logam. Variasi warna ini dapat membantu model mempelajari pola visual yang lebih kompleks.

3) Pertanyaan Bisnis 3

Bagaimana kemampuan fitur hasil ekstraksi gambar dalam membedakan kategori sampah berdasarkan persebaran fitur PCA pada tahap pengembangan model EcoSort AI?



Gambar 3.11 Visualisasi Persebaran Fitur Menggunakan PCA

Berdasarkan visualisasi PCA, terlihat bahwa beberapa kategori sampah membentuk pola persebaran yang cukup terpisah, seperti kategori Organic yang cenderung berada di sisi kanan bawah dan Metal yang lebih terkonsentrasi di bagian kiri bawah, sehingga menunjukkan bahwa fitur hasil ekstraksi gambar mampu menangkap karakteristik visual tertentu dari masing-masing kategori. Namun, beberapa kategori seperti Glass, Plastic, dan Paper masih memiliki banyak titik yang saling bertumpuk, yang mengindikasikan adanya kemiripan karakteristik visual antar kategori tersebut sehingga berpotensi menyebabkan model klasifikasi mengalami kesulitan dalam membedakannya secara akurat.

3.3 Kesimpulan Analisis

Berdasarkan hasil Exploratory Data Analysis dan Explanatory Analysis, proses cleaning berhasil meningkatkan kualitas dataset EcoSort AI melalui penyeragaman ukuran gambar, standardisasi format file, serta penghapusan data duplikat. Analisis karakteristik visual menunjukkan adanya variasi warna dan tingkat kecerahan yang cukup beragam sehingga mampu merepresentasikan kondisi nyata. Selain itu, visualisasi PCA menunjukkan bahwa fitur hasil ekstraksi gambar mampu membedakan beberapa kategori sampah, meskipun masih terdapat kemiripan visual pada beberapa kelas. Secara keseluruhan, dataset dinilai memiliki kualitas yang baik dan siap digunakan untuk pengembangan model klasifikasi sampah.

BAB IV

FEATURE ENGINEERING & A/B TESTING

4.1 Feature Engineering

Feature Engineering merupakan tahapan yang dilakukan untuk menghasilkan representasi fitur yang lebih informatif dari data yang telah melalui proses cleaning data. Pada proyek ini, feature engineering dilakukan melalui proses ekstraksi fitur menggunakan model ResNet50 yang telah dilatih sebelumnya pada dataset gambar. Penggunaan model pre-trained dipilih karena mampu mengekstraksi karakteristik visual yang kompleks tanpa harus melakukan pelatihan model dari awal. Proses ekstraksi fitur diawali dengan memuat seluruh gambar sampah hasil preprocessing. Selanjutnya, seluruh citra diseragamkan ke dalam ukuran 300×300 piksel agar sesuai dengan kebutuhan input model. Sebelum dilakukan ekstraksi fitur, citra diproses menggunakan fungsi preprocess input untuk menyesuaikan format data dengan karakteristik model ResNet50. Hasil dari proses ekstraksi fitur menghasilkan 2.048 fitur untuk setiap gambar sampah. Fitur-fitur tersebut merupakan representasi numerik yang merangkum berbagai karakteristik visual pada gambar, seperti bentuk, tekstur, pola, dan informasi visual lainnya.

	Nama File	Kategori	f0	f1	f2	f3	f4	f5	f6	f7	...	f2038	f2039	f20
0	B3_001.jpg	0	0.318693	0.138918	0.000784	1.577151	0.084531	0.000000	0.125605	0.288635	...	0.117993	0.000000	0.1007
1	B3_002.jpg	0	0.200292	0.221201	0.092287	0.099935	0.645725	0.412312	0.155244	0.067423	...	0.133017	0.878107	0.3246
2	B3_003.jpg	0	0.073939	0.197216	0.132105	0.092837	0.137831	0.550942	0.182247	0.359962	...	3.080773	0.031534	0.0000
3	B3_004.jpg	0	0.152611	0.076287	0.003537	0.000179	0.219657	1.091905	0.192316	0.172373	...	0.593312	1.404355	0.0483
4	B3_005.jpg	0	0.021068	0.194005	0.000000	0.089258	1.284916	0.843956	0.312845	0.666687	...	0.012141	0.135378	0.2155

Gambar 4.1 Contoh Hasil Feature Engineering

Tujuan utama dari feature engineering pada proyek ini adalah mendukung analisis terhadap kualitas representasi fitur yang dihasilkan dari data citra sampah. Fitur yang diperoleh selanjutnya digunakan sebagai dasar dalam analisis Principal Component Analysis (PCA) untuk melihat pola persebaran data berdasarkan kategori sampah. Tahap ini dilakukan untuk menjawab salah satu pertanyaan bisnis yaitu “*Bagaimana kemampuan fitur hasil ekstraksi gambar dalam membedakan kategori sampah berdasarkan persebaran fitur PCA pada tahap pengembangan model EcoSort AI*”.

Berdasarkan visualisasi PCA seperti pada *Gambar 3.11*, terlihat bahwa setiap kategori sampah membentuk pola persebaran fitur yang berbeda. Kategori Organic dan Metal menunjukkan kecenderungan berada pada area yang berbeda, sedangkan kategori lainnya membentuk kelompok persebaran yang khas sesuai karakteristik visual masing-masing. Hasil ini menunjukkan bahwa fitur hasil ekstraksi mampu menangkap informasi visual yang relevan untuk membedakan berbagai jenis sampah.

4.2 A/B Testing

A/B Testing dilakukan untuk mengukur efektivitas beberapa pendekatan yang digunakan dalam pengembangan sistem EcoSort AI. Pengujian dilakukan pada dua dataset yang berbeda, yaitu Dataset Klasifikasi Sampah dan Dataset Rekomendasi Bank Sampah.

4.2.1 A/B Testing Dataset Klasifikasi Sampah

Pengujian dilakukan untuk mengukur pengaruh preprocessing terhadap konsistensi ukuran gambar pada dataset klasifikasi sampah. Tujuan pengujian ini adalah membuktikan bahwa tahapan preprocessing berhasil menghasilkan ukuran gambar yang lebih beragam dibandingkan data awal.

1) Perumusan Hipotesis

H_0 : Tidak terdapat perbedaan signifikan ukuran gambar sebelum dan sesudah preprocessing.

H_1 : Terdapat perbedaan signifikan ukuran gambar sebelum dan sesudah preprocessing.

2) Uji Asumsi

Hasil uji normalitas menunjukkan bahwa data sebelum preprocessing tidak berdistribusi normal ($p\text{-value} < 0,05$), sehingga pengujian dilanjutkan menggunakan Mann-Whitney U Test sebagai metode non-parametrik.

Tabel 4.1 Uji Asumsi A/B Testing Data Klasifikasi Sampah

Uji	P-Value
Normalitas Data Awal	$6,03 \times 10^{-42}$
Normalitas Data Hasil Preprocessing	1,00
Homogenitas (Levene Test)	$7,30 \times 10^{-138}$

3) Hasil Pengujian

Tabel 4.2 Hasil Pengujian A/B Testing Data Klasifikasi Sampah

Statistik	Nilai
U Statistic	915.705
P-Value	$5,37 \times 10^{-37}$
Karena $p\text{-value} < 0,05$, maka H_0 ditolak.	

4) Kesimpulan

Berdasarkan hasil Mann-Whitney U Test, diperoleh $p\text{-value}$ sebesar $5,37 \times 10^{-37}$ yang lebih kecil dari tingkat signifikansi 0,05. Hasil tersebut menunjukkan bahwa terdapat perbedaan yang signifikan antara ukuran gambar sebelum dan sesudah preprocessing. Dengan demikian,

preprocessing yang dilakukan berhasil meningkatkan konsistensi ukuran gambar sehingga data menjadi lebih seragam untuk digunakan pada tahap pengembangan sistem.

4.2.2. A/B Testing Dataset Rekomendasi Bank Sampah

Pengujian dilakukan untuk membandingkan kualitas rekomendasi antara dua metode yang digunakan dalam sistem rekomendasi bank sampah. Pada Metode A rekomendasi dilakukan dengan perhitungan berdasarkan jarak terdekat. Sedangkan pada Metode B rekomendasi dilakukan berdasarkan kombinasi jarak dan kapasitas bank sampah.

1) Perumusan Hipotesis

H_0 : Tidak terdapat perbedaan rata-rata Utility Score antara Metode A dan Metode B.

H_1 : Rata-rata Utility Score Metode B lebih tinggi dibandingkan Metode A.

2) Proses Perhitungan Jarak

Perhitungan jarak dilakukan menggunakan rumus Haversine yang mempertimbangkan kelengkungan bumi sehingga menghasilkan estimasi jarak yang lebih akurat. Pengujian dilakukan melalui simulasi pada beberapa lokasi pengguna untuk membandingkan kualitas rekomendasi yang dihasilkan oleh kedua metode.

3) Hasil Pengujian

Tabel 4.3 Hasil Pengujian A/B Testing Data Bank Sampah

Statistik	Nilai
T-Statistic	8,375
P-Value	$3,13 \times 10^{-9}$
Rata-rata Utility Score Metode A	1,56
Rata-rata Utility Score Metode B	4,93
Karena p-value < 0,05, maka H_0 ditolak.	

4) Kesimpulan

Berdasarkan hasil Paired T-Test, diperoleh p-value sebesar $3,13 \times 10^{-9}$ yang lebih kecil dari tingkat signifikansi 0,05. Hasil tersebut menunjukkan bahwa terdapat perbedaan yang signifikan antara Metode A dan Metode B. Selain itu, rata-rata Utility Score Metode B sebesar 4,93 lebih tinggi dibandingkan Metode A sebesar 1,56. Hal ini menunjukkan bahwa metode yang mempertimbangkan kombinasi jarak dan kapasitas bank sampah mampu menghasilkan rekomendasi yang lebih baik dibandingkan metode yang hanya mempertimbangkan jarak terdekat.

BAB V


DASHBOARD & DEPLOYMENT

5.1. Dashboard Streamlit

Dashboard EcoSort AI dikembangkan menggunakan Streamlit, Python, dan CSS sebagai media visualisasi data yang interaktif. Dashboard ini memanfaatkan dua dataset utama, yaitu dataset klasifikasi sampah dan dataset rekomendasi bank sampah. Selain menyajikan informasi mengenai data yang digunakan dalam proyek, dashboard juga dirancang untuk membantu menjawab tiga pertanyaan bisnis melalui berbagai visualisasi dan analisis data. Dashboard terdiri dari dua halaman utama, yaitu halaman Dataset dan halaman Dashboard Analysis.

5.1.1. Halaman Dataset

Halaman Dataset digunakan untuk menampilkan informasi mengenai dataset yang digunakan dalam pengembangan EcoSort AI, yaitu dataset klasifikasi sampah dan dataset bank sampah. Informasi yang ditampilkan meliputi deskripsi dataset, jumlah data, serta contoh data yang digunakan pada proses pengembangan sistem.



Dataset 2 : Jumlah Lokasi Pengangkutan Sampah Kota Surabaya Tahun 2025

229 Data **37 Kecamatan** **128 Kelurahan**

Nama	Alamat	Kelurahan	Kecamatan	Kapasitas	Volume Masuk	Volume Dikelola	Volume Sampah Ditolah	Volume Diangkut	Lokasi
TPS Pasar Asemrowo	Jl. Asemrowo	Asemrowo	Asemrowo	8	8	8	8	8	-7.243
TPS Jayamix	Jl. Dupak Rukun	Asemrowo	Asemrowo	28	28	28	28	28	-7.243
TPS Genting	Jl. Genting	Asemrowo	Asemrowo	14	14	14	14	14	-7.243
Landasan Tambak Asri	Jl. Tambak Asri	Genting Kallanak	Asemrowo	14	14	14	14	14	-7.236
TPS Greges	Jl. Greges Kallanak	Tambak Sarioso	Asemrowo	14	14	14	14	14	-7.236
TPS Kandangan	Jl. Kandangan	Kandangan	Benowo	14	14	14	14	14	-7.249
TPS Griya Citra Asri	Jl. Perum Griya Citra Asri	Kandangan	Benowo	8	8	8	8	8	-7.249
TPS Rusunawa Romokalisari	Jl. Rusunawa Romokalisari	Romokalisari	Benowo	14	14	14	14	14	-7.202
TPS Bandanjo Sememi	Jl. Bandanjo Pasar Sememi	Sememi	Benowo	14	14	14	14	14	-7.249
Pemilahan TPS 3R Tambak Oso Wilangun	Jl. Tambak Oso Wilangun	Tambak Oso Wilangun	Benowo	20	1175	1175	466	0	-7.218

Buttons: Back, Next, Lihat Sumber Data, Manage app

Gambar 5.1 Halaman Dataset Streamlit

5.1.2. Halaman Dashboard Analysis

Dashboard Explanatory Analysis

Analisis kualitas dataset dan karakteristik visual pada pengembangan model EcoSort AI

[Data Quality](#) [Visual Analysis](#) [Feature Analysis](#)

Data Quality

Apakah kualitas dataset gambar sampah berdasarkan konsistensi ukuran gambar, format file, dan jumlah data duplikat sudah memenuhi kebutuhan proses training model pada tahap persiapan data?

Manage app

Gambar 5.2 Halaman Dashboard Analysis Streamlit

5.2. Deployment Streamlit Cloud

Setelah proses pengembangan dashboard selesai dilakukan, tahap selanjutnya adalah deployment agar dashboard dapat diakses secara online. Pada proyek EcoSort AI, deployment dilakukan menggunakan Streamlit Cloud yang terintegrasi dengan repositori GitHub. Proses deployment dilakukan dengan melengkapi seluruh berkas yang dibutuhkan, seperti kode utama program, dataset yang digunakan, file CSS untuk pengaturan tampilan antarmuka, serta file requirements.txt yang berisi daftar dependensi sistem. Setelah seluruh komponen berhasil dikonfigurasi, dashboard EcoSort AI dapat diakses secara daring melalui tautan berikut:

Link Dashboard EcoSort AI: <https://ecosortdashboard.streamlit.app/>

BAB VI

KESIMPULAN & SARAN

6.1 Kesimpulan

Berdasarkan seluruh tahapan yang telah dilakukan pada proyek EcoSort AI, dapat disimpulkan bahwa sistem berhasil dikembangkan untuk mendukung klasifikasi jenis sampah serta memberikan rekomendasi pengelolaan sampah secara cerdas melalui pemanfaatan teknologi Computer Vision dan sistem rekomendasi berbasis lokasi. Pada tahap data preparation, proses gathering, assessing, dan cleaning data berhasil meningkatkan kualitas dataset melalui penghapusan data duplikat, standarisasi format file, standarisasi ukuran gambar, serta peningkatan kualitas citra. Hasil Exploratory Data Analysis (EDA) menunjukkan bahwa dataset memiliki distribusi yang relatif seimbang antar kategori serta tingkat variasi visual yang cukup representatif untuk menggambarkan kondisi nyata.

Feature engineering menggunakan model ResNet50 berhasil menghasilkan representasi fitur yang mampu menangkap karakteristik visual dari masing-masing kategori sampah. Hasil visualisasi Principal Component Analysis (PCA) menunjukkan bahwa beberapa kategori seperti Organic dan Metal memiliki pola persebaran fitur yang cukup terpisah, meskipun masih terdapat tumpang tindih pada beberapa kategori lain seperti Plastic, Glass, dan Paper. Hasil A/B Testing pada dataset klasifikasi sampah menunjukkan bahwa proses preprocessing memberikan pengaruh signifikan terhadap konsistensi ukuran gambar dengan nilai p-value sebesar $5,37 \times 10^{-37}$. Selain itu, A/B Testing pada sistem rekomendasi bank sampah menunjukkan bahwa metode yang mempertimbangkan kombinasi jarak dan kapasitas bank sampah menghasilkan rekomendasi yang lebih baik dibandingkan metode yang hanya mempertimbangkan jarak, dengan rata-rata Utility Score sebesar 4,93 dan p-value sebesar $3,13 \times 10^{-9}$.

Melalui dashboard berbasis Streamlit yang telah dikembangkan, pengguna dapat mengakses informasi dataset, visualisasi analisis, klasifikasi sampah berbasis gambar, rekomendasi bank sampah terdekat, serta artikel edukasi terkait pengelolaan sampah. Dengan demikian, EcoSort AI mampu menjadi solusi digital yang mendukung pengelolaan sampah yang lebih efektif, edukatif, dan berkelanjutan.

6.2 Saran

Berdasarkan hasil pengembangan dan evaluasi sistem, terdapat beberapa saran yang dapat dilakukan untuk pengembangan EcoSort AI di masa mendatang.

1. Pada pengembangan selanjutnya, jumlah dan variasi dataset dapat ditingkatkan untuk memperkaya informasi yang digunakan dalam proses pelatihan model. Selain menambah jumlah data pada setiap kategori, pengembangan juga dapat dilakukan dengan menambahkan kategori sampah baru. Saat ini EcoSort AI hanya mengklasifikasikan enam kategori sampah, yaitu B3, Glass, Metal, Organic, Paper, dan Plastic. Penambahan kategori lain seperti tekstil, kayu, karet, limbah medis, maupun limbah elektronik yang lebih spesifik diharapkan dapat meningkatkan kemampuan sistem dalam mengenali berbagai jenis sampah secara lebih akurat dan komprehensif.
2. Sistem rekomendasi bank sampah dapat dikembangkan lebih lanjut dengan mengintegrasikan data secara real-time, seperti informasi kapasitas bank sampah terkini, jam operasional, serta jenis sampah yang diterima pada masing-masing lokasi. Integrasi data yang lebih dinamis tersebut diharapkan mampu meningkatkan kualitas rekomendasi yang diberikan kepada pengguna sehingga proses pengelolaan dan penyaluran sampah menjadi lebih efektif, tepat sasaran, dan sesuai dengan kondisi aktual di lapangan.

LAMPIRAN

Dokumentasi Kode Data Scientist	https://drive.google.com/drive/folders/1F77D4vnikA1IwgKqr0UT7autSO_Fj_X2?usp=sharing
Github Kode Data Scientist	https://github.com/MuhamadAlfaRezaGobel23/Data-Scientist-Code-Capstone/